

USER MANUAL

DataCrawler (Harvest) 사용자 매뉴얼

웹 데이터 수집 데스크톱 애플리케이션 — 화면별 기능 안내 및 사용 가이드

버전 대상: DataCrawler v2.0 (Harvest)

문서 작성일: 2026-07-30

대상 독자: 데이터 수집 담당자 / 신규 사용자

목차

01 시작하기 — 화면 구성과 공통 툴바

02 대시보드

03 모니터링 ① Raw 수집 결과 · ② 정제 규칙 설정 · ③ 정제 결과 · ④ Before / After 비교

04 스케줄러

05 통계 분석

06 세션 설정

07 인증 관리

08 부록 — 자주 발생하는 상황과 대처

DataCrawler는 좌측 **내비게이터(사이드바)**, 상단 **전역 툴바**, 그리고 선택한 메뉴에 따라 바뀌는 **본문 영역**으로 구성되어 있습니다. 화면 최하단에는 최근 로그 메시지를 보여주는 **상태바**가 항상 고정되어 있습니다.

좌측 내비게이터는 **NAVIGATOR**(대시보드 / 모니터링 / 스케줄러 / 통계 분석)와 **SETTINGS**(세션 설정 / 인증 관리) 두 그룹으로 나뉩니다. **인증 관리** 메뉴는 현재 불러온 수집 작업(request_info.json)의 인증 방식이 "로그인" 또는 "API 키"로 설정되어 있을 때만 나타납니다 — 인증이 필요 없는 수집 작업에서는 표시되지 않습니다.

전역 툴바 (모든 화면 상단 공통)

구성 요소	설명
방식 라벨 (GET/POST)	현재 수집 작업의 HTTP 요청 방식을 표시합니다. request_info.json의 <code>conditions.method</code> 값입니다.
URL 입력창	수집 대상의 시작 URL을 표시·수정합니다.
URL 복사	입력창의 URL 전체를 클립보드로 복사하고 텍스트를 전체 선택합니다.
▶ 시작 / ■ 중지	수집을 시작하거나 진행 중인 수집을 중지합니다. 시작 시 대시보드의 진행 단계가 "수집 세팅 → 데이터 수집"으로 순차 전환됩니다.


하단 상태바

가장 최근 로그 한 줄을 항상 표시하며, **로그 전체 보기** 버튼을 누르면 전체 로그를 시간순으로 확인할 수 있는 별도 창이 열립니다. 수집 중 오류가 발생하면 이 로그를 가장 먼저 확인하는 것이 좋습니다.

참고

시작 버튼을 누르면 곧바로 수집이 시작되는 것이 아니라 "수집 세팅" 단계(환경 설정 로드)를 거친 뒤 실제 수집이 시작됩니다. 이 사이 약 1초의 지연이 있는 것은 정상 동작입니다.

대시보드는 현재 수집 작업의 **진행 상태를 한눈에 파악**하기 위한 첫 화면입니다. 수집 설정(딜레이/스레드/타임아웃/재시도)을 조정하고, 진행률과 세션 통계, 실시간 수집 결과 테이블을 함께 확인할 수 있습니다.



대시보드 — 작업 진행 상태, 수집 설정, 진행률, 세션 통계, 수집 모니터링 테이블

주요 기능

영역	설명
작업 진행 상태	수집 대기 → 수집 세팅 → 데이터 수집 → 결과물 추출의 4단계를 시각적으로 보여줍니다. 현재 단계는 강조색(보라)으로 표시됩니다.
수집 & 저장 설정	Delay(s): 요청 간 대기 시간(기본 0.5초, 0.5~10초) · Threads: 병렬 수집 스레드 수(1~16, 기본 4) · Timeout(s): 요청 최대 대기 시간(기본 10초) · Retry: 실패 시 재시도 횟수(기본 2회) · Auto Save: 수집 완료 시 결과를 RAW 또는 정제 데이터로 자동 저장
진행률 바	현재 수집의 전체 진행률(%)을 실시간으로 표시합니다.
세션 통계	요청 완료 수, 오류 수, 총 수집 항목 수, 평균 응답 시간을 카드 형태로 보여줍니다.

수집 모니터링 테이블

요청별 URL·상태 코드·IP·User-Agent·쿠키·레이턴시·작업명을 실시간으로 나열합니다. **내보내기** 버튼으로 CSV 저장이 가능합니다.

사용 팁

Threads/Delay 값을 과도하게 높이면(스레드 ↑, 딜레이 ↓) 대상 서버에 부담을 주거나 차단(403/429)될 가능성이 커집니다. 처음 수집하는 사이트라면 기본값(Delay 0.5s, Threads 4)으로 먼저 테스트한 뒤 점진적으로 조정하는 것을 권장합니다.

참고

Auto Save를 켜고 저장 대상을 "정제"로 선택한 경우, **모니터링** → ② **정제 규칙 설정** 탭에서 마지막으로 저장해 둔 규칙이 그대로 적용됩니다. 이번 수집을 위해 규칙을 다시 확인하지 않았다면 의도하지 않은 결과가 저장될 수 있습니다.

모니터링 화면은 수집된 데이터를 확인하고 정제하는 핵심 작업 공간으로, 4개의 탭으로 구성됩니다: ① **Raw 수집 결과** → ② **정제 규칙 설정** → ③ **정제 결과** → ④ **Before / After 비교**. 보통 이 순서대로 작업합니다.

① Raw 수집 결과

수집된 원본 데이터를 항목(컬럼) 단위 테이블로 보여줍니다.

선택 항목 상세
테이블에서 행을 클릭하세요.

NO	상품명	가격	판매자
0	무선 이어폰 Pro	89,000	테크샵
1	블루투스 스피커 Mini	45,000	사운드월드
2	보조배터리 20000mAh	32,900	테크샵
3	무선 이어폰 Pro	89,000	테크샵
4	스마트워치 밴드	18,500	웨어러블샵
5	-	-	-
6	노트북 거치대	24,000	데스크마켓
7	USB-C 허브 7in1	39,900	테크샵
8	게이밍 마우스	56,000	사운드월드

① Raw 수집 결과 — 요약 카드(전체/정상/null/중복) + 실시간 결과 테이블


구성 요소	설명
수집 결과 요약	전체 항목 수, 정상 행 수, 전체 null 행 수, 중복 행 수를 카드로 집계합니다.
검색	테이블 내 모든 컬럼을 대상으로 실시간 필터링합니다.
EXTRACT	현재 Raw 데이터를 파일(CSV/JSON/Excel) 또는 DB로 추출합니다.
⚙️ 추출 설정	추출 대상(FILE/DB), 저장 경로·파일명·형식·인코딩·구분자 또는 DB 접속 정보를 설정하는 다이얼로그를 엽니다.
행 클릭 → 선택 항목 상세	테이블의 특정 행을 클릭하면 하단에 해당 행의 전체 필드 값이 펼쳐집니다.

참고

테이블에서 **주황색 배경**은 모든 필드가 null인 행, **빨간색 배경**은 이전 행과 값이 완전히 동일한 중복 행을 나타냅니다. 정제 실행 전 문제 있는 데이터를 미리 가늠하는 용도로 활용하세요.

② 정제 규칙 설정

Raw 데이터에 적용할 정제 규칙을 선택하고 **정제 실행** 버튼으로 실행합니다.



② 정제 규칙 설정 — 7종 정제 규칙 체크박스

규칙	설명	기본값
커스텀 정제 규칙 적용	이 수집물(seq_no)에 등록된 사용자 정의 정제 함수를 적용합니다.	ON
모든 필드 null 행 제거	모든 필드가 null·빈 값인 행만 삭제합니다.	ON
문자열 공백 trim	문자열 필드의 앞뒤 공백 및 줄바꿈을 제거합니다.	ON
중복 행 제거	모든 컬럼 값이 동일한 행을 1개만 남깁니다.	ON
제외 필드 지정	추출에 불필요한 컬럼을 선택하여 제외합니다. (별도 다이얼로그에서 컬럼 선택)	OFF
결측값(N/A) 치환	삭제 대상 외 결측값을 지정한 값으로 대체합니다.	OFF
숫자 타입 변환		OFF

문자열로 수집된 숫자 필드를 int / float으로 변환합니다.

참고 — 화면 표시 순서 ≠ 실제 처리 순서

체크박스는 위 표의 순서(사용성 기준)로 보이지만, 실제 정제 파이프라인은 ① null 행 제거 → ② 커스텀 규칙 → ③ 공백 trim → ④ 중복 제거 → ⑤ 필드 제외 → ⑥ 결측값 치환 → ⑦ 숫자 변환 순으로 내부 처리됩니다. "커스텀 정제 규칙 적용"을 켜면 null 행 제거·공백 trim·중복 제거가 자동으로 함께 켜집니다(결측값 치환은 자동 연동되지 않음).

③ 정제 결과

정제 실행 후의 데이터와 정제 통계(정제 후 행 수 / 제거된 행 / 치환된 값 / 정제율)를 보여줍니다.

The screenshot shows the DataCrawler interface with the URL `https://example-shop.com/` and the '정제 결과' (Cleaning Results) tab selected. The summary card displays the following statistics:

- 정제 후 행 수 (Rows after cleaning): 7
- 제거된 행 (Rows removed): 2
- 치환된 값 (Values replaced): 0
- 정제율 (Cleaning rate): 77.8%

The table below shows the cleaned data (REFINED) with 7 rows:

NO	상품명	가격	판매자
1	무선 이어폰 Pro	89,000	테크샵
2	블루투스 스피커 Mini	45,000	사운드월드
3	보조배터리 2000mAh	32,900	테크샵
4	스마트워치 밴드	18,500	웨어러블샵
5	노트북 거치대	24,000	데스크마켓
6	USB-C 허브 7in1	39,900	테크샵
7	게이밍 마우스	56,000	사운드월드

The bottom status bar shows: [OK] 정제 완료 — Raw 9행 → 정제 후 7행 (제거 2행, 치환 0건, 정제율 77.8%)

③ 정제 결과 — 정제 요약 카드 + 정제된 데이터 테이블(EXTRACT 가능)

이 탭에서도 Raw 탭과 동일하게 검색·EXTRACT·추출 설정을 사용할 수 있습니다.

④ Before / After 비교

Raw 데이터와 정제 데이터를 좌우로 나란히 놓고 비교합니다. 두 테이블은 스크롤과 정렬이 서로 동기화됩니다.

DataCrawler

GET https://example-shop.com/

URL 복사

▶ 시작

① Raw 수집 결과

② 정제 규칙 설정

③ 정제 결과

④ Before / After 비교

○ 대시보드

■ **모니터링**

⌚ 스케줄러

▲ 통계 분석

● 세션 설정

○ 인증 관리

정제 요약

9

Raw 행 수

7

정제 후 행 수

2

제거된 행

77.8%

정제율

RAW 데이터

9 rows

NO	상품명	가격	판매자
1	무선 이어폰 Pro	89,000	테크샵
2	블루투스 스피커 ...	45,000	사운드월드
3	보조배터리 2000...	32,900	테크샵
4	무선 이어폰 Pro	89,000	테크샵
5	스마트워치 밴드	18,500	웨어러블샵
6	-	-	-
7	노트북 거치대	24,000	데스크마켓
8	USB-C 허브 7in1	39,900	테크샵
9	게이밍 마우스	56,000	사운드월드

정제 데이터

7 rows

NO	상품명	가격	판매자
1	무선 이어폰 Pro	89,000	테크샵
2	블루투스 스피커 ...	45,000	사운드월드
3	보조배터리 2000...	32,900	테크샵
4	스마트워치 밴드	18,500	웨어러블샵
5	노트북 거치대	24,000	데스크마켓
6	USB-C 허브 7in1	39,900	테크샵
7	게이밍 마우스	56,000	사운드월드

● 연결됨

[OK] 정제 완료 — Raw 9행 → 정제 후 7행 (제거 2행, 치환 0건, 정제율 77.8%)


로그 전체 보기 ▲

④ Before / After 비교 — 좌: Raw 데이터, 우: 정제 데이터 (스크롤·정렬 동기화)

사용 팁

정제 규칙을 변경한 뒤에는 반드시 **정제 실행**을 다시 눌러야 ③·④ 탭에 최신 결과가 반영됩니다. 규칙만 바꾸고 실행하지 않으면 이전 정제 결과가 그대로 남아있으니 주의하세요.

반복적인 수집 작업을 자동 실행되도록 예약하는 화면입니다. 등록된 작업 목록과 다음 실행까지 남은 시간을 확인할 수 있습니다.



스케줄러 — 등록된 작업 목록 + Next Task 카운트다운

구성 요소	설명
등록된 작업 테이블	Task Name·URL·Execution Time(반복 주기)·Next Runtime(남은 시간)·Status·수정/삭제 버튼을 보여줍니다.
Status 색상	대기(주황) · 실행 중(초록) · 완료(파랑) · 비활성(회색)
Next Task	가장 임박한 예약 작업명과 남은 시간을 실시간 카운트다운으로 표시합니다.
+ 작업 추가	새 스케줄 등록 다이얼로그를 엽니다.

새 스케줄 등록 / 수정 다이얼로그

수집 설정과 저장 설정을 함께 지정하여 하나의 예약 작업으로 저장합니다. "저장 대상"을 **정제**로 선택하면 오른쪽에 정제 규칙 패널이 가로로 확장되어 나타나며, 모니터링 페이지의 정제 규칙 설정과 동일한 7종 규칙을 스케줄 전용으로 별도 지정할 수 있습니다.

새 스케줄 등록

기본 정보

Task Name

작업명을 입력하세요|

Target URL

https://example-shop.com/products?page=\${page:1:1:10}

수집 설정

Delay(s)

0.5

Thread

4

Timeout(s)

10

Retry

3

SAVE SETTING

출력 대상

FILE

DB

로컬 파일 저장 모드

저장 대상

RAW

정제

경로

C:\Users

Browse

파일명

untitled0

형식

CSV

인코딩

UTF-8 BOM

구분자

,

저장 방식

선택하세요

INTERVAL

주기

선택하세요

적용

취소

새 스케줄 등록 다이얼로그 — 기본 정보, 수집 설정, 저장 설정, 반복 주기(INTERVAL)

항목	설명
Task Name / Target URL	스케줄 목록에 표시될 작업명과 수집 대상 URL입니다.
Delay / Thread / Timeout / Retry	대시보드와 동일한 의미의 수집 파라미터입니다.
출력 대상 (FILE / DB)	파일 저장 또는 DB 전송을 선택합니다. 파일 모드는 경로·파일명·형식 (CSV 등)·인코딩·구분자를 지정합니다.

저장 대상 (RAW / 정제)	수집 직후 원본을 저장할지, 정제 규칙을 적용한 뒤 저장할지 선택합니다.
INTERVAL (반복 주기)	매일 / 매주 / 매월 / 특정일 중 선택하고 실행 시각(시:분:초)을 지정합니다.

주의

스케줄 자동 실행 중에는 화면을 막는 팝업(정제 규칙 없음 경고 등)이 뜨지 않고 로그로만 남습니다 — 무인 실행 특성상 당연한 동작이지만, 예약 작업이 조용히 스킵되었을 수 있으므로 실행 후에는 **로그 전체 보기**로 결과를 확인하는 습관을 들이세요. 또한 "제외 필드 지정" 규칙은 Raw 데이터를 미리 봐야 설정할 수 있는 규칙이라 스케줄 정제 패널에는 포함되지 않습니다.

지금까지 수행한 수집 작업들의 누적 통계를 시각화하여 보여주는 화면입니다. 3초마다 자동으로 갱신됩니다.




통계 분석 — KPI 카드, 상태 코드 도넛 차트, 응답 시간 분포, 시간대별 추이, 세션 이력

구성 요소	설명
KPI 카드	총 수집 항목, 성공률(상태 코드 200 비율), 평균 응답 시간, 완료 세션 수를 요약합니다.
상태 코드 분포	200/301/404/429/500 등 응답 상태 코드별 비중을 도넛 차트와 범례로 보여줍니다.
응답 시간 분포	순수 응답 지연시간을 0.2초 단위 구간으로 나눈 막대 차트입니다.
시간대별 수집량 추이	최근 12시간의 성공/오류 건수 추이를 선 그래프로 보여줍니다.
세션 이력	완료된 수집 세션별 총 항목·성공·오류·평균 응답·소요 시간·시작/완료 시각을 나열합니다.

참고

이 화면의 모든 통계는 **현재 앱을 실행 중인 동안 메모리에 누적된 데이터**를 기준으로 계산됩니다. 프로그램을 재시작하면 통계가 초기화되며, 과거 세션 데이터를 영구 보관하려면 세션 이력 상단의 리포트 내보내기 기능(JSON)을 이용해 별도로 저장해 두어야 합니다.

수집 시 사용할 세션 옵션(User-Agent, 쿠키)과 프록시 관련 설정을 관리하는 화면입니다.



세션 설정 — 세션 옵션, 프록시 옵션, 프록시 목록

구성 요소	설명
UA 랜덤 / Cookie 랜덤	요청마다 User-Agent 또는 쿠키 세션을 무작위로 교체합니다. 이미 쿠키가 설정된 요청에는 Cookie 랜덤이 적용되지 않습니다.
전역 프록시 사용	이 스위치를 켜야 아래 프록시 옵션·목록 카드가 활성화됩니다.
자동 로테이션	여유 있는 프록시를 무작위로 순회하며 할당하고, 가용 프록시가 모두 소진되면 지연 후 재시도합니다.
연결 전 헬스체크	프록시 사용 전 연결 가능 여부를 사전 점검합니다.
분당 IP 허용 갯수 / MAX RETRY	프록시 1개당 분당 허용 요청 수와 실패 시 최대 재시도 횟수입니다.
프록시 목록	등록된 프록시의 활성 여부·프로토콜·호스트·포트·레이턴시·상태를 테이블로 관리합니다. + 추가 로 직접 등록하거나 Import 로 텍스트/CSV 파일에서 IP:PORT 형식의 목록을 일괄 불러올 수 있습니다. 행을 우클릭하면 삭제 메뉴가 나타납니다.

프로시 목록의 **활성** 체크박스는 행을 클릭하는 것만으로도 토글됩니다 — 목록이 길 때 실수로 활성/비활성 상태가 바뀌지 않도록 주의하세요.

로그인이 필요한 사이트를 수집하거나 API 라이선스 키가 필요한 수집물을 다룰 때 사용하는 화면입니다. 앞서 설명한 대로, 현재 불러온 수집 작업이 인증을 요구하지 않으면 이 메뉴 자체가 사이드바에 나타나지 않습니다.

The screenshot shows the DataCrawler application interface. On the left is a sidebar with a 'NAVIGATOR' section containing '대시보드', '모니터링', '스케줄러', and '통계 분석', and a 'SETTINGS' section containing '세션 설정' and '인증 관리' (which is selected). The main area is titled '인증 관리' and contains several sections: '전역 인증 옵션' with checkboxes for 'TLS/SSL 인증서 검증', '인증 정보 암호화 저장', and '세션 자동 갱신' (the first is checked); '로그인 대상 설정' with input fields for '사이트 URL' (https://example-shop.com/login), '아이디' (demo_user), and '비밀번호' (masked); and '로그인 셀렉터' and '성공 판별 키워드' with example values. At the bottom, there is a status bar showing '연결됨' and a log entry.

인증 관리 — 로그인 방식(authMethod: "login")인 경우의 화면

전역 인증 옵션 (공통)

항목	설명
TLS/SSL 인증서 검증	인증서 유효성을 엄격하게 검증할지 여부입니다.
인증 정보 암호화 저장	ID/PW 또는 키 값을 암호화하여 보관할지 여부입니다.
세션 자동 갱신	세션 만료 시 자동으로 재로그인/재발급을 시도할지 여부입니다.

로그인 방식 (authMethod: "login")

항목	설명
사이트 URL	로그인 폼이 있는 페이지의 URL입니다.

아이디 / 비밀번호	로그인에 사용할 계정 정보입니다. 비밀번호 입력창은 마스킹 처리됩니다.
로그인 셀렉터	로그인 버튼의 CSS 셀렉터(선택사항) — 비워두면 자동 탐지를 시도합니다.
성공 판별 키워드	로그인 성공 후 나타나는 페이지에서 확인할 키워드(예: "마이페이지", "dashboard")입니다.

API 키 방식(authMethod: "api_key")인 경우에는 이 영역 대신 자격증명(API Key / Cookie / OAuth2 / Basic Auth / Bearer Token) 목록 테이블이 표시되며, + **자격증명 추가**로 항목을 등록하고 **내보내기(암호화)**로 백업할 수 있습니다.

보안 주의

이 화면에는 실제 로그인 자격 증명이 평문으로 입력됩니다. 화면 캡처나 화면 공유, 로그 전달 시 이 페이지가 노출되지 않도록 각별히 주의하세요. 특히 원격 지원이나 문의 시 스크린샷을 첨부할 경우, 아이디·비밀번호 입력창을 반드시 가린 뒤 전달해야 합니다.

상황	대처 방법
수집을 시작해도 모니터링 테이블에 아무 것도 안 뜸	하단 상태바의 최근 로그와 로그 전체 보기 를 확인하세요. 대상 사이트의 구조 변경으로 XPath/선택자가 더 이상 일치하지 않거나, 인증이 필요한 페이지인데 인증 관리 설정이 비어 있는 경우가 흔한 원인입니다.
EXTRACT 버튼을 눌러도 추출이 안 됨	먼저 추출 설정 에서 출력 대상(FILE/DB)과 상세 값(경로/파일명 또는 DB 접속 정보)이 올바르게 채워져 있는지 확인하세요.
"정제 규칙 없음" 경고가 뜸	이 수집물이 커스텀 정제 규칙이 필요하도록 표시되어 있으나, 등록된 규칙 파일이 없다는 의미입니다. 관리자에게 해당 seq_no의 정제 규칙 등록을 요청하거나, "커스텀 정제 규칙 적용"을 끄고 범용 규칙만으로 진행할 수 있습니다.
스케줄이 등록됐는데 실행되지 않음	Status가 "비활성"은 아닌지, Next Runtime 카운트다운이 정상적으로 줄어드는지 확인하세요. 예약 실행 시점에 다른 수집 작업이 이미 진행 중이었다면 대기열에 순서대로 보관되었다가 이전 작업 종료 후 실행됩니다.
중지 버튼을 눌렀는데 반응이 늦음	진행 중이던 요청이 정리되는 짧은 지연이 있을 수 있습니다. 중지 후에는 대시보드 진행 단계가 "수집 대기"로 초기화되는 것으로 정상 중지 여부를 확인할 수 있습니다.

DataCrawler(Harvest) 사용자 매뉴얼 · 본 문서의 화면 이미지는 안내 목적의 샘플 데이터로 구성되었으며 실제 수집 데이터와 무관합니다.